

FlipFlop

El equipo de FlipFlop, una reconocida app social nos han encomendado la realización de un módulo de IA, moderador de imágenes y texto.

En dicha app, los usuarios pueden compartir fotos, imágenes y escribir publicaciones. Con el rápido crecimiento que está teniendo, la app actualmente cuenta con más de 10k MAU; y se espera duplicar dicha cifra hacia finales del año.

Para cumplir con los términos y condiciones de la empresa y las guidelines para la subida de fotos y publicaciones dentro de la app, las cuales son visibles por el resto de los usuarios; se requiere automatizar la moderación de imágenes y texto dentro de la app. Actualmente dicha moderación es realizada por un equipo moderador desde un web admin. No obstante, con el éxito de la app, el equipo no da a vasto para moderar la creciente cantidad de imágenes y publicaciones realizadas por los usuarios.

Para la moderación de imágenes, se propuso utilizar [Modraptor](#); para la moderación de texto, se usará [sightengine](#). No obstante, se espera poder ser reemplazados por [The Hive](#), que ofrece un servicio todo en uno, más complejo y preciso, aunque también más costoso.

Cuando un usuario suba una foto o realice una publicación en la app, la misma será analizada por nuestro módulo moderador. Se sabe que cada una de las fotos y texto analizado por la IA arroja diferentes valores, tomando en cuenta la probabilidad que la foto o texto contengan:

Clase Moderación, iModeraciónImágenes : clase Modraptor implements iModeraciónImágenes
iModeraciónDeTexto : clase Sightengine implements iModeraciónDeTexto

ENUM

- Desnudez
- Celebridad
- Símbolos agresivos
- Gestos ofensivos
- Armas
- Drogas
- Alcohol
- Marcas de agua

Main Facade: usuario carga foto

Cada una de las probabilidades varían entre 0 y 1 (donde 0 es no contiene dicha ocurrencia y 1 indica la presencia de dicha categoría).

clase Validacion

clase LógicaValidacion

Según el resultado de la moderación de las imágenes, se debe aprobar o rechazar la imagen/publicación del usuario. Si el resultado cae dentro de determinados valores considerados “dudosos”, la foto deberá ser enviada para la moderación manual por parte del equipo moderador. Los resultados serán como se indican a continuación:

- Valores entre 0 y 0.2: **APROBADO**
- Valores entre 0.2 y 0.8: **ENVIADO A REVISIÓN**

- Valores superiores a 0.8: **RECHAZADO**

En los casos de aprobación o rechazo, el usuario será notificado en la app a través de un push notification. En caso de ser enviado a revisión por parte de un moderador, se emitirá un alerta en el web admin y se visualizará la imagen/publicación en el panel de moderación respectivo.